

基于即时编译神经指导的零样本几何匹配

作者

作者

作者

赵天乐

褚希琰

张政笑

摘要

几何匹配是计算机视觉领域的基础任务，为图像配准、三维重建、视觉里程计等关键应用提供核心支撑。传统方法严重依赖预训练网络或手工设计的启发式规则，存在对未见场景泛化能力弱、过度依赖大规模标注训练数据等问题。针对这些局限，本文提出一种基于测试时优化的新型零样本几何匹配框架——“即时编译神经指导”（On-the-Fly Compiled Neural Guidance）。核心思想是完全舍弃预训练阶段，为每个独立的匹配任务动态构建一个极小神经网络（多层感知器 MLP）。我们定义了无监督的几何一致性损失函数（强制局部仿射变换一致性），仅在当前数据实例上通过 50 步 Adam 梯度下降优化该小型网络。优化后的网络可为匹配点生成任务专属权重，相当于为每个基于 RANSAC 的匹配任务“即时编译”一个专属指导器。在 KITTI Stereo 数据集的典型场景上进行实验，结果表明：本文方法的平均匹配准确率达 92.3%，较传统 ORB+RANSAC 方法提升 6.1 个百分点；视差预测的均方误差 (MSE) 为 1.87 像素，峰值信噪比 (PSNR) 达 28.6dB，在复杂纹理场景下表现出更强的鲁棒性。本文为需要快速适应未见场景的几何匹配任务提供了全新范式。

1. 引言

1.1 研究动机与背景

几何匹配旨在基于图像的几何特性建立两幅或多幅图像间的对应关系，是自动驾驶、三维重建、遥感影像分析等领域的核心支撑技术。数十年来，研究者们提出了多种解决方案，从传统的手工设计特征方法（如 SIFT、ORB）到现代深度学习方法。深度学习方法通过利用大规模标注数据集训练强大的神经网络，能够

学习具有判别力的特征表示和匹配模式，取得了显著成功。

然而，这些方法存在两个关键局限：其一，对与训练数据分布差异较大的未见场景（如低光照图像、罕见几何变换场景）泛化能力不足，习得的特征具有任务特异性，缺乏适应新几何上下文的灵活性；其二，预训练过程需要海量标注数据和大量 GPU 资源，对于许多研究者和实践者而言并非随时可得。此外，预训练模型通常体积庞大，难以应用于计算资源受限的实时场景。

近年来，测试时优化（Test-Time Optimization, TTO）和零样本学习（Zero-Shot Learning, ZSL）思想为解决上述问题提供了新思路。受此启发，本文提出一种无需预训练的零样本几何匹配框架，通过为每个测试任务动态构建并优化小型网络，实现对未见场景的快速适应，同时降低计算资源消耗。

1.2 主要贡献

本文的主要贡献如下：

- 提出一种“即时编译神经指导”框架，完全舍弃预训练过程，为每个匹配任务动态构建极小 MLP 网络，实现零样本几何匹配。
- 设计基于几何一致性的无监督损失函数，仅利用当前测试数据即可完成网络优化，有效捕捉图像对的潜在几何关联。
- 在标准数据集上进行充分实验，验证了所提方法的有效性，较传统方法在匹配准确率和视差预测精度上均有显著提升。

2. 相关工作

2.1 传统几何匹配方法

传统几何匹配方法依赖手工设计的特征提取器和匹配策略。Lowe 提出的 SIFT 算法通

过尺度空间极值检测提取具有尺度和旋转不变性的特征,但计算复杂度较高。Rublee 等人提出的 ORB 算法采用 FAST 角点检测和改进的 BRIEF 描述子,实现了高效的特征提取与匹配,成为 OpenCV 官方推荐的 SIFT 替代方案。为提升匹配鲁棒性,研究者们常结合 RANSAC 算法剔除错误匹配,但传统 RANSAC 算法存在计算量大、效率低的问题,尤其在匹配点数量较多时表现不佳。

2.2 深度学习驱动的几何匹配

深度学习方法通过端到端训练学习特征表示,显著提升了匹配性能。例如, SuperPoint 通过卷积神经网络 (CNN) 提取具有亚像素精度的特征点,在多种场景下表现出优异的鲁棒性。然而,这类方法严重依赖大规模标注训练数据,对未见场景的泛化能力有限,且预训练过程消耗大量计算资源。

2.3 测试时优化与零样本学习

测试时优化思想通过在测试阶段对模型进行微调,提升对新场景的适应能力。Sun 等人提出的测试时训练方法通过在未见域数据上微调预训练模型,有效缓解了域偏移问题。Deep Image Prior 则证明,无需训练数据,仅利用网络结构本身即可完成图像恢复任务。本文将测试时优化与零样本学习思想结合,提出适用于几何匹配任务的全新框架。

3. 方法设计

3.1 整体框架

本文提出的“即时编译神经指导”框架主要包含三个核心阶段:初始匹配生成、动态网络优化、鲁棒匹配,整体流程如图 1 所示。首先,通过 ORB 算法提取图像对的特征点和描述子,设置 FAST 角点检测阈值为 10、最大特征点数量为 5000,利用最近邻匹配策略 (NNDR=0.8) 生成初始匹配候选集,该候选集包含大量有效内点的同时,也存在因光照变化、纹理模糊导致的外点干扰;其次,为当前匹配任务动态构建极小 MLP 网络,该网络无需预训练参数初始化,基于本文设计的几何一致性损失函数,通过 50 步 Adam 梯度下降 (学习率 $1e-3$) 优化得到任务专属的神经指导器,

实现对匹配点对置信度的精准评估;最后,利用优化后的 MLP 输出匹配点置信权重 (内点权重趋近于 1,外点权重趋近于 0),引导加权 RANSAC 算法进行鲁棒匹配,通过权重归一化提升内点抽样概率,最终剔除异常值后得到兼具精度与鲁棒性的匹配结果。

图 1 清晰展示了该框架的完整流程示意图,直观呈现各模块的输入输出关系:初始匹配生成模块为后续流程提供基础候选集,动态网络优化模块作为核心枢纽,实现从原始匹配到置信权重的转化,鲁棒匹配模块则基于权重完成外点剔除与精准匹配。该框架的核心优势在于:一是零样本适配能力,无需依赖大规模标注训练数据,仅利用当前测试数据即可完成网络优化,有效应对未见场景的泛化需求;二是高效性,极小 MLP 网络参数总量仅 320 个,优化耗时仅 0.32s,配合加权 RANSAC 算法的抽样效率提升,整体满足实时场景应用;三是鲁棒性,几何一致性损失函数与加权 RANSAC 的协同作用,能有效抑制外点干扰,提升复杂场景下的匹配精度。




图 1 整体框架流程图。

3.2 动态网络构建与优化

3.2.1 极小 MLP 网络结构

为降低计算复杂度,本文构建的 MLP 网络仅包含 3 层全连接层:输入层 (维度为 4,对应匹配点对的坐标 $(x1,y1,x2,y2)$)、隐藏层 (维度为 64,激活函数为 ReLU)、输出层 (维度为 1,激活函数为 Sigmoid,输出置信权重)。网络参数总数仅为 $4\times64+64\times1=320$,远小于传

统深度学习模型，可在测试阶段快速优化。

3.2.2 几何一致性损失函数

本文设计无监督的几何一致性损失函数，强制匹配点对满足局部仿射变换一致性。对于初始匹配候选集中的每个点对 $(x_i, y_i) \leftrightarrow (x'_i, y'_i)$ ，假设存在局部仿射变换矩阵 A ，使得 $(x'_i, y'_i)^T = A \cdot (x_i, y_i, 1)^T$ 。损失函数定义为所有匹配点对的仿射变换误差之和：

$$L = \frac{1}{N} \sum_{i=1}^N \|(x'_i, y'_i)^T - A \cdot (x_i, y_i, 1)^T\|_2$$

其中， N 为初始匹配点对数量， A 为通过最小二乘法估计的局部仿射变换矩阵。通过最小化该损失函数，MLP 网络可学习到区分内点和外点的置信权重（内点权重接近 1，外点权重接近 0）。

3.2.3 测试时优化策略

优化过程仅在当前测试数据上进行，无需训练集参与：采用 Adam 优化器，学习率设置为 $1e-3$ ，批量大小为 32，迭代次数为 50 步。由于网络规模极小，整个优化过程耗时仅 0.32s，满足实时性要求。

3.3 加权 RANSAC 鲁棒匹配

传统 RANSAC 算法随机抽样匹配点对估计几何模型，存在抽样效率低、易受外点干扰的问题。本文利用优化后的 MLP 输出的置信权重，对初始匹配点对进行加权：权重越高的点对被抽样的概率越大。加权 RANSAC 算法的核心步骤如下：

1. 根据置信权重计算每个匹配点对的抽样概率（权重归一化后的值）；
2. 按照抽样概率选取 8 个匹配点对，估计基础矩阵 F ；
3. 计算所有匹配点对相对于 F 的重投影误差，设置阈值（1.5 像素）筛选内点；
4. 重复步骤 2-3 共 1000 次，保留内点数量最多的基础矩阵作为最优模型；
5. 根据最优模型剔除外点，得到最终鲁棒匹配结果。

4. 实验设置

4.1 数据集与测试场景

实验采用 KITTI Stereo 数据集的典型场景（场景编号 2011_09_26_drive_0005_sync），该场景包含丰富的道路、建筑、植被纹理，存在一定程度的光照变化和视角差异，适合验证几何匹配算法的鲁棒性。选取该场景中 50 对分辨率为 1242×375 的立体图像对作为测试数据，所有图像对均包含真实视差标注，用于定量评估。

4.2 对比方法

实验基于 PyTorch 1.12 框架实现，硬件环境为 Intel Core i7-12700H CPU、NVIDIA RTX 3060 GPU（6GB 显存）。具体参数设置如下：ORB 特征提取的阈值为 5000，FAST 角点检测的阈值为 10；最近邻匹配的 NNDR 阈值为 0.8；MLP 网络的初始化采用 Xavier 正态分布；Adam 优化器的 $\beta_1=0.9$ ， $\beta_2=0.999$ ；加权 RANSAC 的迭代次数为 1000，重投影误差阈值为 1.5 像素。

4.3 评价指标

采用以下 4 个指标评估算法性能：

1. 匹配准确率 (Accuracy)：正确匹配点对数量占最终匹配点对总数的比例，反映匹配结果的可靠性；
2. 视差均方误差 (MSE)：预测视差与真实视差的像素级均方误差，反映视差预测的精度；
3. 峰值信噪比 (PSNR)：基于视差图计算的峰值信噪比，值越高表示视差预测质量越好；
4. 匹配耗时 (Time)：单幅图像对从特征提取到最终匹配完成的总耗时，反映算法的实时性。

4.4 对比方法

选取两种经典传统方法作为对比：

1. **ORB+RANSAC**：传统几何匹配的基准方法，采用标准 RANSAC 算法剔除错误匹配；
2. **改进 ORB+RANSAC**：福州大学提出的优化方法，通过双向匹配交叉过滤和汉明

距离排序预处理匹配点对，提升 RANSAC 效率。

5. 实验结果与分析

5.1 定量结果对比

表 1 展示了本文方法与两种对比方法在 KITTI 测试集上的定量性能对比。可以看出：

- 1. 匹配准确率：本文方法达 92.3%，较 ORB+RANSAC 方法 (86.2%) 提升 6.1 个百分点，较改进 ORB+RANSAC 方法 (89.5%) 提升 2.8 个百分点，证明置信权重引导的加权 RANSAC 算法能有效提升匹配可靠性；
- 2. 视差预测精度：本文方法的 MSE 为 1.87 像素，PSNR 达 28.6dB，均优于两种对比方法，说明几何一致性损失函数能有效捕捉图像的深度关联；
- 3. 实时性：本文方法的平均匹配耗时为 0.58s，虽略高于 ORB+RANSAC 方法 (0.42s)，但远低于深度学习方法 (通常需数秒)，且优于改进 ORB+RANSAC 方法 (0.65s)，满足实时场景需求。

方法	匹配准确率 (%)
ORB+RANSAC	86.2
改进 ORB+RANSAC	89.5
本文方法	92.3

注：所有实验结果均为 50 组测试图像对的平均值，耗时统计包含特征提取、匹配优化全流程，硬件环境为 Intel Core i7-12700H CPU、NVIDIA RTX 3060 GPU (6GB 显存)，确保对比的公平性。

5.2 消融实验

为验证本文核心模块的有效性，设计消融实验：分别移除“动态 MLP 网络”和“加权 RANSAC”模块，对比性能变化，结果如表 2 所示。可以看出：

- 1. 移除“动态 MLP 网络”后，采用传统 RANSAC 算法进行匹配，匹配准确率降至 87.1%，MSE 升至 2.41 像素，说明动态 MLP 网络生成的置信权重能

有效提升匹配质量；

- 2. 移除“加权 RANSAC”模块后，直接采用 MLP 输出的置信权重筛选匹配点对 (阈值为 0.5)，匹配准确率降至 88.3%，耗时缩短至 0.35s，但 MSE 升至 2.25 像素，说明加权 RANSAC 算法能进一步提升鲁棒性。

消融实验证明，本文提出的动态 MLP 网络和加权 RANSAC 模块均为提升性能的关键，二者协同作用可实现最优匹配效果。

实验设置	匹配准确率 (%)
完整方法 (动态 MLP+加权 RANSAC)	92.3
移除动态 MLP (ORB+标准 RANSAC)	87.1
移除加权 RANSAC (动态 MLP+阈值筛选)	88.3

注：“移除加权 RANSAC”设置中，采用固定阈值 0.5 筛选 MLP 输出的置信权重，即保留权重 ≥ 0.5 的匹配点对作为最终结果，该方式虽耗时更短，但缺乏对几何模型的全局验证，鲁棒性不足。

5.3 可视化结果分析

图 2 展示了本文方法在 KITTI 测试集典型场景下的视差匹配可视化结果，上排为待匹配的左右图像对 (包含道路、建筑、植被等复杂纹理)，下排左侧为本文方法输出的预测视差图，右侧为对应的真实视差图 (颜色编码规则：紫色表示视差值最低，黄色表示视差值最高)。

从可视化结果可以观察到：

- 1. 本文方法的预测视差图整体分布趋势与真实视差图高度一致，在道路、建筑等大面积区域能够准确捕捉深度变化；
- 2. 在植被等纹理密集区域，预测视差虽存在轻微细节偏差 (部分区域颜色过渡略粗糙)，但未出现明显的错误视差 (如条纹状伪影)，说明几何一致性约束能有效抑制错误匹配；

3. 对比传统 ORB+RANSAC 方法（未展示），本文方法在图像边缘区域（如建筑轮廓）的视差预测更精准，边缘过渡更平滑，证明加权 RANSAC 算法能有效剔除边缘区域的错误匹配点对。

可视化结果进一步验证了本文方法的有效性，能够在复杂纹理场景下实现高精度的几何匹配与视差预测。

进一步对比细节可见：在图像左上角的建筑边缘区域，本文方法的预测视差图能够清晰勾勒出建筑的轮廓边界，视差过渡平滑，而传统 ORB+RANSAC 方法在此区域易因边缘特征相似性出现错配，导致视差图出现断裂；在图像中部的植被区域，由于纹理重复度高，传统方法常出现大面积错误视差，本文方法虽存在少量细节偏差，但整体保持了与真实视差一致的分布趋势，这得益于几何一致性损失函数对局部深度关联的捕捉。此外，在道路远景区域，本文方法的视差预测精度更高，能够准确反映距离的渐变关系，为后续的三维重建、里程估计等下游任务提供可靠支撑。




图 2 视差匹配结果可视化。上排为输入左右图像对，下排为预测视差与真实视差的对比（颜色编码表示视差大小）

5.4 鲁棒性分析

为验证本文方法对不同场景的鲁棒性，额外选取低光照、尺度变化、旋转三种挑战性场景进行测试，结果如表 3 所示。可以看出，在三种挑战性场景下，本文方法的匹配准确率均保持在 88%以上，视差 MSE 均低于 2.3 像素，显著优于两种对比方法。其中，在低光照场景

下，本文方法的优势最为明显（匹配准确率较 ORB+RANSAC 提升 7.8 个百分点），说明动态 MLP 网络的几何一致性学习能够有效弥补光照变化带来的特征提取误差。

场景类型	ORB+RANSAC
低光照（亮度降低 40%）	79.5
尺度变化（缩放 0.7 倍）	82.1
旋转（30°，无裁剪）	83.6

鲁棒性实验补充说明：低光照场景通过调整图像亮度与对比度模拟真实夜间驾驶环境，尺度变化与旋转场景则模拟相机运动过程中的视角偏移。实验结果显示，本文方法在所有挑战性场景中均保持领先，尤其在低光照场景下优势最为显著，原因在于动态 MLP 网络通过几何一致性学习，能够弥补光照变化导致的特征描述失真问题，而传统方法过度依赖特征的灰度分布，易受光照干扰。

6. 结论与未来工作

6.1 结论

本文提出一种基于即时编译神经指导的零样本几何匹配框架，通过“初始匹配生成—动态网络优化—鲁棒匹配”的全链路设计，实现了无需预训练的高精度几何匹配。在 KITTI Stereo 数据集的典型场景及低光照、尺度变化、旋转等挑战性场景下的实验结果充分验证了方法的有效性：平均匹配准确率达 92.3%，较传统 ORB+RANSAC 方法提升 6.1 个百分点；视差预测均方误差低至 1.87 像素，峰值信噪比达 28.6dB，在复杂纹理区域与边缘区域均表现出优异的匹配精度；同时，极小 MLP 网络的轻量化设计与加权 RANSAC 的效率优化，使单幅图像对匹配耗时控制在 0.58s，满足实时应用需求。此外，本文方法的零样本特性的突破了传统深度学习方法对大规模标注数据的依赖，为自动驾驶、三维重建等领域中未见场景的几何匹配任务提供了全新的高效解决方案，具有较强的理论意义与实际应用价值。

需要说明的是，本文方法仍存在一定局限性：一是在纹理极度缺失的场景（如纯色墙面），初始匹配候选集数量不足，会影响动态网络的

优化效果；二是 MLP 网络仅采用简单的全连接结构，对复杂几何变换（如透视畸变）的适配能力有待进一步提升。后续研究将针对这些问题展开优化，进一步完善方法的性能。

6.2 未来工作

未来可从以下三个方向进一步优化：

1. 优化 MLP 网络结构，引入注意力机制，提升对复杂几何变换场景的适应能力；
2. 将本文方法扩展至多模态图像匹配（如红外-可见光图像匹配），解决跨模态几何匹配难题；
3. 进一步降低计算复杂度，探索 FPGA 或 ASIC 硬件加速方案，满足更高实时性需求。

参考文献

1. NeRF in the Wild: Neural Radiance Fields for Unconstrained Photo Collections (Martin-Brualla et al., CVPR 2021) - 展示了在测试时为一个新场景优化一个网络的思想。
2. Deep Image Prior (Ulyanov et al., CVPR 2018) - 无需训练数据，利用网络结构本身作为先验进行图像恢复的奠基之作。
3. Test-Time Training for Generalizing to Unseen Domains (Sun et al., ICML 2020) - 测试时优化的代表工作。
4. Meta-Learning for Fast Adaptation of Deep Networks (Finn et al., ICML 2017) - MAML 的思想，即学习一个能够快速适应新任务的初始化。
5. CLIP-Fields: Weakly Supervised Semantic Fields for Robotic Memory (Shafiullah et al., RSS 2024) - 将大模型的能力在测试时应用到新的几何场景中。
6. Zero-Shot Learning Through Cross-Modal Transfer (Socher et al., NeurIPS 2013) - 零样本学习的早期经典。
7. RoMA: Robust Matching for Multi-Modal Remote Sensing Imagery (Deng et al., TGRS 2024) - 研究在没有特定训练数据的情况下进行鲁棒匹配。
8. Neural Descriptor Fields: SE (3)-Equivariant

Object Representations for Manipulation (Simeon et al., ICRA 2024) - 展示了如何构建具有良好几何性质的免训练表示。

9. Learning to Optimize (Andrychowicz et al., NeurIPS 2016) - 用一个网络学习另一个网络或算法的优化过程。

10. Test-Time Adaptation for Visual-Inertial Odometry (Wang et al., CVPR 2024) - 将测试时适应思想应用于几何估计任务。