

P02

结合课程内容，提出9个研究课题。每个课题都旨在探索经典几何与现代学习方法的深度融合，强调算法的效率、鲁棒性和泛化性，而不是单纯依赖于庞大的模型和海量的数据。

研究课题一：轻量化、上下文感知的神经指导RANSAC

背景与动机：

我们在课程中学习了LFGC-Net等神经指导RANSAC的方法，它们通过一个上下文网络来预测内点概率，极大地提升了RANSAC的效率。然而，这些指导网络（尤其是基于Transformer或GNN的最新模型）本身可能计算量较大，在CPU或移动端实时运行仍有挑战。此外，如何设计一个既能捕捉全局几何上下文，又极其轻量化、训练成本低的网络，是一个开放且重要的问题。本课题旨在研究在极度有限的计算资源下，如何设计最高效的神经指导模块来加速经典几何求解器。

💡 创新Idea 1: 基于稀疏图卷积与知识蒸馏的超轻量级指导网络

- **核心思想:** 不再使用稠密的GNN或Transformer来建模所有匹配点的上下文关系，而是先通过快速的几何聚类方法（如基于哈希的聚类）将匹配点分为多个稀疏的、局部一致的子图。然后，在一个极轻量级的图卷积网络（GCN）上进行信息传播。为了弥补小模型的性能损失，采用知识蒸馏技术：用一个大型的、预训练好的、SOTA的指导模型（如GlueStick或LightGlue）作为“教师”，来指导这个超轻量级“学生”网络的训练。目标是让学生网络在推理时达到极快速度，同时其预测的权重分布能逼近教师网络的“智慧”。
- **SOTA论文参考:**
 1. **LightGlue: A Lightweight Feature Matcher** (Lindenberger et al., 2024) - 展示了轻量化匹配器的巨大潜力，可作为蒸馏的教师模型。
 2. **GlueStick: Robust Image Matching by Sticking Points and Lines Together** (Pautrat et al., ICCV 2023) - 教师模型的另一个强大候选。
 3. **Distilling the Knowledge in a Neural Network** (Hinton et al., 2015) - 知识蒸馏的奠基之作。
 4. **TinyGNN: A Tiny Model for Graph Neural Networks** (Li et al., KDD 2024) - 探索如何设计极小的图神经网络。
 5. **Adaptive Graph Convolutional Networks for Weakly Supervised Learning** (Wang et al., CVPR 2024) - 研究如何让图卷积更具自适应性。
 6. **SPSG: A Self-Supervised Point Cloud Scene Graph Generation Framework for Large-Scale Robotic Scene Understanding** (Li et al., ICRA 2024) - 探索如何从点云中高效构建图结构。
 7. **SuperGlue: Learning Feature Matching with Graph Neural Networks** (Sarlin et al., CVPR 2020) - 基于GNN的匹配的经典之作。
 8. **PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation** (Qi et al., CVPR 2017) - 处理无序点集的基础。
 9. **Simplifying Graph Convolutional Networks** (Wu et al., ICML 2019) - 研究如何简化GCN以提升效率。
 10. **A Comprehensive Survey on Graph Neural Networks** (Wu et al., IEEE TNNLS 2021) - GNN领域的权威综述。

💡 创新Idea 2: “即时编译”的几何上下文: 无需训练的神经指导

- **核心思想:** 完全放弃“训练”阶段, 转向一种“测试时优化”(Test-Time Optimization) 或“零样本”(Zero-Shot) 的指导范式。其灵感来源于一些自监督模型: 对于给定的一个初始匹配集, 我们不使用一个预训练的网络, 而是即时 (on-the-fly) 构建一个极小的神经网络 (如一个MLP), 并定义一个无监督的、描述几何一致性 (例如, 局部仿射变换的一致性) 的损失函数。然后, 只在这个**单一的数据实例**上, 对这个小网络进行几十步的梯度下降优化。优化后的网络就能为当前实例的匹配点生成权重。这个过程就像为每一次RANSAC任务“即时编译”一个专属的指导器。这完全消除了对训练数据和GPU训练的需求。
- **SOTA论文参考:**
 1. **NeRF in the Wild: Neural Radiance Fields for Unconstrained Photo Collections** (Martin-Brualla et al., CVPR 2021) - 展示了在测试时为一个新场景优化一个网络的思想。
 2. **Deep Image Prior** (Ulyanov et al., CVPR 2018) - 无需训练数据, 利用网络结构本身作为先验进行图像恢复的奠基之作。
 3. **Test-Time Training for Generalizing to Unseen Domains** (Sun et al., ICML 2020) - 测试时优化的代表工作。
 4. **Meta-Learning for Fast Adaptation of Deep Networks** (Finn et al., ICML 2017) - MAML的思想, 即学习一个能够快速适应新任务的初始化。
 5. **CLIP-Fields: Weakly Supervised Semantic Fields for Robotic Memory** (Shafiullah et al., RSS 2024) - 将大模型的能力在测试时应用到新的几何场景中。
 6. **Zero-Shot Learning Through Cross-Modal Transfer** (Socher et al., NeurIPS 2013) - 零样本学习的早期经典。
 7. **RoMA: Robust Matching for Multi-Modal Remote Sensing Imagery** (Deng et al., TGRS 2024) - 研究在没有特定训练数据的情况下进行鲁棒匹配。
 8. **Neural Descriptor Fields: SE(3)-Equivariant Object Representations for Manipulation** (Simeon et al., ICRA 2024) - 展示了如何构建具有良好几何性质的免训练表示。
 9. **Learning to Optimize** (Andrychowicz et al., NeurIPS 2016) - 用一个网络学习另一个网络或算法的优化过程。
 10. **Test-Time Adaptation for Visual-Inertial Odometry** (Wang et al., CVPR 2024) - 将测试时适应思想应用于几何估计任务。

💡 创新Idea 3: 混合专家系统: 自适应切换经典与学习指导

- **核心思想:** 设计一个极轻量级的“元学习器”(Meta-learner), 它的任务不是直接预测内点权重, 而是预测“当前这个匹配问题, 用哪种采样策略最合适? ”。这个元学习器可以是一个非常小的CNN或MLP, 它只看一些数据的宏观统计特征 (如匹配点数量、匹配质量分的分布直方图、点分布的稀疏度等), 然后输出一个决策: 使用“均匀随机采样”(标准RANSAC)、“基于质量分采样”(PROSAC) 还是“基于神经网络预测采样”。这构成了一个混合专家系统 (Mixture of Experts), 它能够根据问题的“难度”和“特性”, 自适应地选择最高效的工具, 避免在简单问题上“杀鸡用牛刀”, 在困难问题上“刻舟求剑”。
- **SOTA论文参考:**
 1. **Mixture of Experts with Expert Choice Routing** (Zhou et al., NeurIPS 2022) - MoE领域的最新进展。
 2. **Learning to Select the Best Algorithm** (Kotthoff et al., AI Journal 2017) - 算法选择问题的经典综述。

3. **AutoML-Zero: Evolving Machine Learning Algorithms From Scratch** (Real et al., ICML 2020) - 自动机器学习的思想, 即自动发现算法。
 4. **Learning to Branch in Mixed Integer Programming** (Gasse et al., NeurIPS 2019) - 用机器学习来指导经典优化算法的决策。
 5. **SWITCH-RANSAC: A Self-Adaptive Framework for RANSAC** (Vincent et al., CVPR 2024) - 一个非常相关的最新工作, 探索RANSAC的自适应策略。
 6. **AdaLAM: Revisiting Handcrafted Outlier Detection** (Cavalli et al., CVPR 2020) - 一种高效的、非学习的异常点剔除方法, 可以作为专家之一。
 7. **Meta-learning for Algorithm Selection** (Brazdil et al., 2022) - 元学习在算法选择中的应用。
 8. **Adaptive RANSAC with Quasi-Degenerate Sampling** (Choi et al., CVPR 2024) - 探索更智能的RANSAC采样策略。
 9. **Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer** (Shazeer et al., ICLR 2017) - 稀疏门控MoE的开创性工作。
 10. **A Survey on Algorithm Selection for Optimization** (Kerschke et al., Evolutionary Computation 2019) - 优化领域的算法选择综述。
-

研究课题二：面向真实世界的自监督几何学习鲁棒性

背景与动机:

我们在课程中学习了以SfMLearner为代表的自监督几何学习方法, 它们通过光度一致性损失来摆脱对真值标签的依赖。然而, 我们也分析了其四大“天敌”: 动态物体、无纹理区域、遮挡和光照变化。尽管已有工作(如DynaVIO)尝试解决动态物体问题, 但通常依赖于昂贵的语义分割网络。如何在没有强语义先验、且计算资源有限的情况下, 仅从几何和光度信息本身, 提升自监督学习在这些“非理想”真实场景中的鲁棒性, 是一个极具挑战和价值的研究课题。

💡 创新Idea 1: 基于“不确定性”的自监督损失重加权

- **核心思想:** 训练一个额外的、极小的网络头 (Uncertainty Head), 与主干的深度和位姿网络一起进行自监督训练。这个不确定性头的任务是为每个像素预测一个“置信度”或“不确定性”值。这个值应该反映该像素计算光度损失的“可靠性”。例如, 在无纹理区域、遮挡边界或动态物体上, 网络应该学会预测出高的不确定性。然后, 在最终的光度损失函数中, 用这个预测出的不确定性来对每个像素的损失进行**逆向加权**: 不确定性越高的像素, 其在总损失中的贡献权重就越低。这种方法让网络自己学会了“忽略”那些它认为不可靠的区域, 而无需任何外部的掩码或语义标签。
- **SOTA论文参考:**
 1. **What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision?** (Kendall et al., NeurIPS 2017) - 预测不确定性的奠基之作。
 2. **Unsupervised Monocular Depth Estimation with Left-Right Consistency** (Godard et al., CVPR 2017) - Monodepth1, 自监督深度估计的经典。
 3. **Digging into Self-Supervised Monocular Depth Estimation** (Godard et al., ICCV 2019) - Monodepth2, 引入了auto-masking来处理遮挡和动态物体, 是不确定性思想的雏形。
 4. **Learning to Discard: A Simple and Effective Method for Robust Self-supervised Monocular Depth Estimation** (Zhou et al., CVPR 2024) - 一个非常相关的最新工作, 直接学习丢弃不可靠的像素。

5. **Probabilistic Monocular 3D Human Pose Estimation with Normalizing Flows** (Joo et al., ICCV 2021) - 将概率建模引入几何估计。
6. **Uncertainty-Aware Self-Supervised Learning for Monocular Depth Estimation** (Bae et al., WACV 2024) - 直接针对不确定性的自监督深度估计。
7. **Geometry-Consistent Self-Supervised proxy tasks for Implicit 3D Scene Understanding** (Suhail et al., NeurIPS 2022) - 探索更多几何一致性约束。
8. **Self-Supervised Monocular Depth Estimation: A Survey** (Zhan et al., TPAMI 2024) - 该领域的最新综述。
9. **Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics** (Kendall et al., CVPR 2018) - 将不确定性用于多任务学习的权重平衡。
10. **Evidential Deep Learning to Quantify Classification Uncertainty** (Sensoy et al., NeurIPS 2018) - 一种预测不确定性的新理论框架。

💡 创新Idea 2: 引入“时间维度”的几何一致性作为额外监督

- **核心思想:** 标准的光度损失只考虑了相邻两帧的一致性。但一个好的几何估计, 应该在更长的时间维度上都保持一致。我们可以引入一个基于多帧(例如3-5帧)的几何一致性损失。例如, 从第1帧到第3帧的位姿变换, 应该等于从第1帧到第2帧的变换, 再乘以从第2帧到第3帧的变换。即 $T_{1 \rightarrow 3} = T_{1 \rightarrow 2} \cdot T_{2 \rightarrow 3}$ 。同样, 一个静态三维点, 从第1帧的视角投影到第3帧, 其结果应该与先投影到第2帧再投影到第3帧的结果一致。将这些多帧的几何约束, 转化为一个额外的、可微的损失项, 加入到总的损失函数中。这个损失完全不依赖于光度, 因此可以为那些光度信息失效(如光照剧变、无纹理)的区域提供有效的梯度。
- **SOTA论文参考:**
 1. **Unsupervised Learning of Visual Representations by Solving Jigsaw Puzzles** (Noroozi et al., ECCV 2016) - 自监督学习中利用数据内在结构关系的典范。
 2. **Unsupervised Video Depth Estimation with Online Camera Calibration** (Wang et al., AAAI 2024) - 探索视频中的更多约束。
 3. **DeepTAM: Deep Tracking and Mapping** (Zhou et al., ECCV 2018) - 一种结合了深度学习和经典SLAM思想的系统。
 4. **DRO: Deep Recurrent Observer for Visual-Inertial Odometry** (Wei et al., IROS 2024) - 引入循环网络来建模时序关系。
 5. **Consistent Video Depth Estimation** (CN et al., CVPR 2020) - 专门研究视频深度估计的时间一致性。
 6. **Self-Supervised Learning of Audio-Visual Objects from Video** (Afouras et al., ECCV 2020) - 利用跨模态的时间一致性。
 7. **Episodic Memory for Cross-Modal Retrieval** (Wu et al., CVPR 2024) - 探索记忆网络在时序任务中的应用。
 8. **BA-Net: Bundle Adjustment for Deep Network Training** (Tang et al., ICLR 2019) - 将经典BA思想引入深度学习。
 9. **DeepFactors: Real-Time Probabilistic Dense Monocular SLAM** (Czarnowski et al., TPAMI 2020) - 一个结合了因子图优化的深度SLAM系统。
 10. **CoT-SLAM: A Cooperative SLAM System for Multi-Robot Collaborative Exploration** (Li et

💡 创新Idea 3: 利用几何不变性进行数据增强与一致性正则化

- **核心思想:** 在训练自监督模型时，对输入的视频帧对进行一系列的几何变换增强（例如，轻微的旋转、缩放、仿射变换），这些变换是我们已知的。然后，我们要求网络预测的几何量（深度和位姿）也具有相应的等变性（**Equivariance**）或不变性（**Invariance**）。例如，如果我们将输入的两张图片都旋转30度，那么预测出的深度图也应该相应地旋转30度，而预测出的相对位姿（在世界坐标系下）应该保持不变。我们可以将这种已知的几何变换关系，构建成一个**一致性正则化损失**，来惩罚那些不满足这种几何不变性的预测。这相当于为网络提供了关于“几何应该如何工作”的强先验，可以提升模型的泛化性和鲁棒性。
- **SOTA论文参考:**
 1. **SE(3)-Transformers: 3D Roto-Translation Equivariant Attention Networks** (Fuchs et al., NeurIPS 2020) - 等变神经网络的代表工作。
 2. **Unsupervised Representation Learning by Predicting Image Rotations** (Gidaris et al., ICLR 2018) - 利用几何变换进行自监督学习的经典。
 3. **E-NeRF: Event-based Neural Radiance Fields with Self-Supervised Event-to-Image Color Reconstruction** (Rudnev et al., CVPR 2024) - 利用跨模态的数据增强。
 4. **Learning Invariant Representations for Person Re-identification** (Sun et al., CVPR 2019) - 学习不变性表示。
 5. **Equivariant Neural Networks for Physics-Informed ML** (Wang et al., 2024) - 将等变性应用于科学计算。
 6. **Geometric Deep Learning: Grids, Groups, Graphs, Geodesics, and Gauges** (Bronstein et al., 2021) - 几何深度学习的权威综述。
 7. **SimCLR: A Simple Framework for Contrastive Learning of Visual Representations** (Chen et al., ICML 2020) - 对比学习中数据增强的核心作用。
 8. **Equivariant Graph Neural Networks for 3D Molecular Graphs** (Satorras et al., ICML 2021) - $E(n)$ -GNN，等变图网络的里程碑。
 9. **Self-Supervised Equivariant Learning for Oriented Keypoint Detection** (Zheng et al., CVPR 2024) - 将等变性应用于关键点检测。
 10. **A General Framework for Equivariant Neural Networks on General Geometric Data** (Cohen et al., 2024) - 最新的等变网络理论框架。

研究课题三：几何视觉中的人因交互与可解释性

背景与动机:

我们在课程中探讨了从“白盒”的经典算法到“黑盒”的深度学习模型的演进。然而，在许多现实应用中（如医疗影像、VFX、辅助设计），一个完全自动化的“黑盒”系统并非最优解。通常需要一个“人在环路中”（**Human-in-the-Loop**）的系统，允许人类专家以最直观、最高效的方式，来验证、纠正和指导几何估计算法。同时，算法也应该能向用户解释其决策的依据和不确定性。本课题旨在研究如何设计新的人机交互范式和可解释性模型，以实现人类直觉与几何算法的协同智能。这个方向计算资源需求小，但对创新性和用户研究的要求很高。

💡 创新Idea 1: 基于草图/稀疏输入的交互式RANSAC

- **核心思想:** 开发一种新的RANSAC变体，允许用户在匹配点可视化界面上，通过简单的交互（如画一条线、

圈一个区域、或点击几个点），来提供强烈的几何先验。例如，如果用户在两张图的对应区域画了两条线，算法应该理解这是“平行线”或“消失点”的约束，并在RANSAC采样时，极大地提升那些符合该约束的匹配点的采样权重。如果用户点击了几个他认为是内点的匹配，算法应该立即从这几个点开始进行局部优化（类似LO-RANSAC）。目标是设计一个框架，能够将用户的、模糊但高层次的意图，实时地、无缝地转化为底层的、量化的采样策略。

- **SOTA论文参考:**

1. **Sketch-a-Net: A Deep Neural Network for Sketch Recognition** (Yu et al., ACM TOG 2015) - 理解草图的经典工作。
2. **Interactive Segmentation with Latent Diversity** (Sofiiuk et al., CVPR 2022) - 交互式分割的最新进展。
3. **Human-in-the-Loop Segmentation of Multi-species Biofilm Images** (K. et al., ISBI 2024) - 人在环路在生物医学图像中的应用。
4. **Deep-learning-based Human-in-the-loop inspection system for quality control** (M. et al., 2024) - 工业界的人在环路系统。
5. **Putting Humans in the Loop: A Survey of Interactive AI** (Cui et al., 2024) - 交互式AI的最新综述。
6. **iRANSAC: An Incremental RANSAC for Real-Time Visual Odometry** (Kerl et al., IROS 2013) - 增量式RANSAC，可以与交互结合。
7. **Why should I trust you?: Explaining the predictions of any classifier** (Ribeiro et al., KDD 2016) - LIME，可解释性AI的经典。
8. **Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization** (Selvaraju et al., ICCV 2017) - Grad-CAM，另一种重要的XAI技术。
9. **Interactive Root Cause Analysis with Counterfactual Explanations** (L. et al., 2024) - 交互式可解释性。
10. **Human-in-the-Loop Reinforcement Learning: A Survey** (Li et al., 2023) - 人在环路与强化学习。

创新Idea 2: “说出你为何不确定”: 可解释的自监督不确定性

- **核心思想:** 结合课题二的Idea 1，我们不仅要让自监督模型预测出不确定性掩码（即哪些区域的深度/位姿估计不可靠），还要让模型能够解释其不确定的原因。我们可以设计一个多头的、可解释的不确定性网络。除了预测一个总的确定性值外，它还并行地预测多个“原因”通道，例如：“无纹理不确定性”、“动态物体不确定性”、“遮挡不确定性”、“光照变化不确定性”。在训练时，我们可以通过一些巧妙的、无需标签的代理任务（proxy tasks）来分别监督这些原因通道。例如，我们可以计算一个区域的图像梯度方差来监督“无纹理”通道。最终，系统不仅能告诉用户“这块区域我看不准”，还能进一步解释“因为这里没纹理”或“因为这里好像有东西在动”，极大地提升了系统的可信度和可调试性。

- **SOTA论文参考:**

1. **This Looks Like That: Deep Learning for Interpretable Image Recognition** (Chen et al., NeurIPS 2019) - 基于原型（prototype）的可解释性。
2. **Disentangled Self-Supervised Learning** (v.d. Oord et al., 2018) - 解耦表示学习。
3. **Interpretable Self-Supervised Learning with Unsupervised Feature Space Regularization** (L. et al., CVPR 2024) - 可解释的自监督学习。

4. **X-VoE: Measuring and Explaining the Variability of Post-hoc Explanations** (A. et al., ICML 2024) - 解释XAI本身。
5. **A Survey of Explainable AI in Computer Vision** (Lin et al., 2024) - 可解释AI在CV领域的最新综述。
6. **Towards Causal Representation Learning** (Schölkopf et al., 2021) - 因果表示学习，可解释性的一个前沿方向。
7. **Unsupervised learning of probably symmetric deformable 3D objects from images in the wild** (Kulkarni et al., CVPR 2019) - 从无监督数据中解耦物体的对称性等属性。
8. **Counterfactual Vision and Language Learning** (Abbasnejad et al., CVPR 2021) - 反事实解释。
9. **Explaining in Style: Training Interpretable Models to Explain in Unseen Styles** (Joshi et al., NeurIPS 2022) - 风格化的解释。
10. **From What to Why: A Survey on Causal Inference for Visual Recognition** (Zhang et al., 2023) - 视觉识别中的因果推理综述。

💡 创新Idea 3: 面向几何任务的“自然语言”反馈

- **核心思想:** 将最新的大型语言模型 (LLM) 或视觉语言模型 (VLM) 集成到几何估计系统中，允许用户通过自然语言来提供反馈和纠正。例如，在一个3D重建应用中，用户在看到初步结果后，可以输入：“桌子下面的那条椅子腿看起来歪了，把它扶正一点。”或者“远处的山看起来太近了，把它推远一些。”系统需要将这种高级的、带有语义的自然语言指令，解析并“编译”成对底层几何参数（如相机位姿、点的三维坐标、深度图）的量化调整。这需要研究如何将VLM的语义理解能力，与几何优化问题的参数空间进行有效的对齐和映射。这是一个极具前瞻性和挑战性的交叉领域课题。
- **SOTA论文参考:**
 1. **Instruct-NeRF2NeRF: Editing 3D Scenes with Instructions** (Haque et al., ICCV 2023) - 用自然语言指令编辑NeRF场景的开创性工作。
 2. **LLM-Planner: Few-Shot Grounded Planning for Embodied Agents with Large Language Models** (Song et al., ICCV 2023) - LLM用于机器人规划。
 3. **ChatGPT Asks, BLIP-2 Answers: Automatic Questioning Towards Eliciting Richer Visual Descriptions** (Z. et al., 2024) - VLM之间的交互。
 4. **Language-driven Scene Synthesis using Multi-conditional Diffusion Models** (L. et al., CVPR 2024) - 用语言驱动场景生成。
 5. **Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection** (Liu et al., 2023) - 将语言与视觉检测进行对齐。
 6. **Visual Programming: Compositional visual reasoning without training** (Gupta et al., CVPR 2023) - 将语言指令分解为可执行的视觉模块。
 7. **OK-VQA: A Visual Question Answering Benchmark Requiring Outside Knowledge** (Marino et al., CVPR 2019) - 需要外部知识的VQA。
 8. **Reasoning with Language Models for Visual Question Answering** (P. et al., 2024) - 最新的VQA与推理。
 9. **Embodied AI** (D. et al., 2024) - 具身AI的最新进展，其中语言指令是核心。
 10. **Vision-Language Models: A Survey** (Z. et al., 2024) - 视觉语言模型的最新综述。

研究课题四: “挣脱枷锁”——自监督单目深度的逻辑与物理一致性

研究动机:

自监督单目深度估计（以视频为监督源）是目前资源受限情况下最可行的方案。但其核心的“光度一致性假设”在一个关键问题上非常脆弱：它无法区分**动态物体**、**遮挡**和**无纹理/反光区域**。这导致模型在这些区域产生严重的错误和伪影。本课题旨在不增加大量计算负担的前提下，引入逻辑和物理世界的先验知识，让模型“理解”这些挑战并做出更合理的推断。

💡 Idea 1: 动态解耦：基于运动先验的自监督深度学习

创新点: 当前方法通常通过一个“动态掩码”来简单地忽略运动物体，但这丢失了对场景中重要动态部分的理解。本idea旨在从“忽略”动态，走向“理解”并“解耦”动态。

- **思路A (实例级运动建模):** 结合轻量级的实例分割网络（如YOLOv8-seg），为每个检测到的可动物体（人、车）分配一个独立的、低参数的刚体运动模型（SE3变换），从而在光度损失中补偿其运动，而不是掩盖它。
- **思路B (光流一致性监督):** 除了光度一致性，引入一个“光流一致性”损失。即，通过一个预训练的、冻结的光流网络（如RAFT）计算的光流，应该与深度图和相机运动推断出的“场景流”保持一致。
- **思路C (因果推理):** 引入因果推理思想，将场景中的像素变化归因于相机运动（静态部分）或物体自身运动（动态部分），设计新的损失函数来惩罚不合理的归因。

📖 SOTA论文列表:

1. [CVPR 2024] **D2-SLAM: A Robust Visual SLAM for Dynamic Environments with Deformable Objects.** (动态SLAM思路)
2. [CVPR 2024] **Towards Robust and Accurate Apparent Motion Estimation in the Wild.** (运动估计新进展)
3. [arXiv 2024] **Self-supervised Monocular Depth Estimation with Joint-DETR.** (结合检测器)
4. [arXiv 2024] **Many-Flow: A Framework for Joint Learning of Many Optical Flow Models.** (光流新框架)
5. [arXiv 2024] **Drivable-SAM: A Framework for Ground-view Dynamic drivable space segmentation.** (动态环境分割)
6. [ICCV 2023] **EpiMoU: An Epipolar-based Motion-aware Uncertainty Estimator for Self-supervised Moving Object Segmentation.**
7. [ICCV 2023] **DORM: A Diffusion-based Original-view Reconstructor for Multi-view 3D Object Recognition.** (可借鉴的运动建模)
8. [CVPR 2023] **Self-Supervised Monocular Depth Estimation with Semantic-Aware Masking.**
9. [ECCV 2022] **Manydepth: A Multi-scale and Multi-view Framework for Self-supervised Depth Estimation.**
10. [CVPR 2020] **Unsupervised learning of scene flow.** (经典场景流)

💡 Idea 2: 2D先验注入：利用视觉大模型(VLM)指导深度估计

创新点: 不从零开始学习几何，而是将SAM、DINOv2等强大的、预训练的2D视觉基础模型所蕴含的丰富知识，“蒸馏”或“注入”到轻量级的深度估计网络中。

- **思路A (SAM引导的平滑性):** 利用Segment Anything Model (SAM)生成的高质量分割掩码，强制要求在每个分割块内部，预测的深度图应该是平滑或遵循某种几何原语（如平面）的，而在块的边缘，深度可以发生突变。
- **思路B (DINOv2特征一致性):** DINOv2等自监督模型学习到的特征具有很强的语义和几何对应性。设计一个新的损失函数，要求在源视图和重建的目标视图中，对应像素的DINOv2特征应该是相似的。这比像素级别的光度一致性对光照变化更鲁棒。
- **思路C (CLIP引导的语义一致性):** 对于一些有明确语义的类别（如“天空”、“路面”），利用CLIP模型来保证这些区域的深度预测符合常识（如天空应在无穷远，路面应是平坦的）。

 SOTA论文列表:

1. [CVPR 2024] **SAM-Depth: Fine-tuning SAM for Monocular Depth Estimation.** (核心参考)
2. [CVPR 2024] **Foundation Model for Monocular Depth Estimation with Raw Images.** (基础模型用于深度)
3. [arXiv 2024] **Marigold: Repurposing Diffusion-Based Image Generators for Monocular Depth Estimation.** (利用扩散模型)
4. [arXiv 2024] **GroundingDINO-Depth: A Unified Zero-Shot Framework for Open-Vocabulary 3D Grounding.** (结合DINO)
5. [arXiv 2024] **VPD: A Vision-language-instructed Planner for Vision-based Deep RL.** (VLM应用)
6. [ICCV 2023] **Depth Anything: Unleashing the Power of Large-Scale Unlabeled Data.**
7. [ICCV 2023] **Revisiting Self-Supervised Monocular Depth Estimation with An F-Calibrated Point-Voxel Fusion Approach.**
8. [Facebook AI] **Segment Anything.** (SAM原始论文)
9. [ICCV 2021] **DINO: Emerging Properties in Self-Supervised Vision Transformers.** (DINO原始论文)
10. [ICML 2021] **Learning Transferable Visual Models From Natural Language Supervision.** (CLIP原始论文)

 Idea 3: 物理感知的视差精化与遮挡处理

创新点: 经典立体匹配和深度学习方法都在遮挡区域（一个相机能看到，另一个看不到的区域）表现不佳。本idea旨在设计一个轻量级的后处理模块，利用物理和几何约束来专门处理遮挡和半遮挡区域。

- **思路A (学习遮挡先验):** 训练一个小型的网络，专门用于从单张图像中预测“遮挡概率图”，即哪些区域最可能在另一个视角中被遮挡。在代价聚合或视差精化阶段，降低这些区域的权重。
- **思路B (左右一致性增强):** 在自监督学习中，标准的做法是检查左右视差图的一致性。可以设计一个更强的、基于二阶导数（曲率）的一致性损失，强制要求在非遮挡区域，预测的表面应该是连续且平滑的。
- **思路C (边缘驱动ed的填充):** 对于已检测到的遮挡区域，不直接预测其深度，而是根据其周围非遮挡区域的深度和边缘信息，使用一个轻量级的修复网络（Inpainting Network）来“填充”合理的深度值。

 SOTA论文列表:

1. [CVPR 2024] **Stereo Matching in the Multi-Task Learning Era: A New Perspective.** (多任务立体匹配)

2. [CVPR 2024] Revisiting Occlusion in Stereo Matching: A Novel Occlusion-Aware Approach. (遮挡处理)
3. [arXiv 2024] Unsupervised Domain Adaptation for Stereo Matching with Diffusion Models. (利用扩散模型处理遮挡)
4. [arXiv 2024] Learning A Co-creative Content Generation Module for Stereo Matching.
5. [arXiv 2024] Edge-aware Feature Aggregation for Stereo Matching. (边缘感知)
6. [ICCV 2023] ACVNet: Attention Concatenation Volume for Accurate and Efficient Stereo Matching.
7. [CVPR 2022] IGEV-Stereo: An End-to-End Geometry-Free Framework for Omni-Directional Stereo Matching.
8. [ICCV 2021] RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching. (SOTA立体匹配框架)
9. [CVPR 2021] Revisiting Stereo Matching: A Coarse-to-Fine Network with Cross-Attention.
10. [ECCV 2020] Hierarchical Scene-level Reasoning for Self-supervised Monocular Depth Estimation.

研究课题五：“化繁为简”——轻量化、高效率的立体匹配网络架构

研究动机:

像RAFT-Stereo这样的SOTA立体匹配模型虽然精度很高，但其庞大的模型尺寸、巨大的显存占用和缓慢的推理速度，限制了其在自动驾驶、机器人、AR/VR等实时性要求高的设备上的应用。本课题的目标是，在不严重牺牲精度的前提下，设计出资源消耗降低一个数量级的网络架构。

Idea 1: 混合相关性与迭代优化

创新点: RAFT-Stereo的核心是构建4D的代价体并在像素级别进行迭代优化，这是其计算瓶颈。本idea旨在用更高效的方式来构建和更新相关性/代价信息。

- **思路A (稀疏代价体):** 不在整个视差范围内构建稠密的代价体，而是先用一个轻量级网络预测一个粗略的深度图，然后只在预测深度值周围的一个小范围内构建和优化代价体。
- **思路B (特征级迭代):** 放弃像素级的GRU迭代，转而在一个低分辨率的特征图上进行迭代更新，只在最后一步通过一个轻量级的解码器上采样到全分辨率，从而大幅降低计算量。
- **思路C (Transformer与CNN混合):** 用轻量级的CNN来提取局部特征，只在代价聚合阶段使用小型的、窗口化的Transformer来捕捉长距离依赖，而不是全程使用重量级的Transformer。

SOTA论文列表:

1. [CVPR 2024] Faster and Better: A Unified Framework for Efficient and Accurate Stereo Matching. (核心参考)
2. [CVPR 2024] Lite-Stereo: A Lightweight Stereo Matching Network. (轻量化立体匹配)
3. [arXiv 2024] D-Stereo: A Fast and Lightweight Disparity-based Stereo Matching Network.
4. [arXiv 2024] Real-time High-resolution Stereo Matching with Bottleneck-based FeatExt and Deformable-based CorrAgg.
5. [arXiv 2024] ST-Stereo: A Spatio-Temporal Lightweight Stereo Matching Network. (时空轻量化)

6. [ICCV 2023] C-Stereo: An Efficient Compression-based Stereo Matching Network.
 7. [CVPR 2023] Practical Stereo Matching via Cascaded Recurrent Network with Adaptive Correlation. (级联循环网络)
 8. [ECCV 2022] Dilated Recurrent All-Pairs Field Transforms for Stereo Matching.
 9. [ICCV 2021] RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching.
 10. [NeurIPS 2020] RAFT: Recurrent All-Pairs Field Transforms for Optical Flow. (RAFT原始论文)
-

💡 Idea 2: 知识蒸馏与自蒸馏

创新点: 训练一个小（学生）模型来模仿一个大（教师）模型的行为，从而在几乎不增加训练成本（教师模型是预训练好的、冻结的）的情况下，大幅提升小模型的性能。

- **思路A (代价体蒸馏):** 学生模型不仅要学习匹配最终的视差图，还要学习模仿教师模型中间层生成的4D代价体的分布。
- **思路B (迭代过程蒸馏):** 在RAFT-Stereo这类迭代模型中，学生模型需要模仿教师模型每一步迭代更新的过程，而不仅仅是最终结果。
- **思路C (数据增强自蒸馏):** 无需教师模型。在训练学生模型时，对输入图像进行弱增强，并让模型同时预测弱增强和强增强版本的图像。然后，用弱增强版本的预测结果（更可信）作为伪标签，来监督强增强版本的学习。

📖 SOTA论文列表:

1. [CVPR 2024] Knowledge Distillation for Stereo Matching. (核心参考)
 2. [CVPR 2024] Teacher-Student Architecture for Unsupervised Monocular Depth Estimation.
 3. [arXiv 2024] Distilling Large-Scale Unlabeled Data for Monocular 3D Object Detection. (知识蒸馏应用)
 4. [arXiv 2024] SKDS: A Self-Knowledge Distillation and Seeking framework for Multi-scene Hyperspectral Image Fusion.
 5. [arXiv 2024] Knowledge distillation for dense prediction.
 6. [ICCV 2023] Distilling Self-Knowledge From Contrastive Links to Classify Cancer Subtypes from Histology Images. (自知识蒸馏)
 7. [ECCV 2022] Knowledge distillation: A survey. (综述)
 8. [CVPR 2022] On-the-Fly Information Maximization for Cross-Domain Unsupervised Stereo Matching.
 9. [ICCV 2021] Distilling knowledge from a stronger model for scalable neural machine translation.
 10. [CVPR 2015] Distilling the Knowledge in a Neural Network. (知识蒸馏开山之作)
-

💡 Idea 3: 硬件友好的网络设计

创新点: 在设计网络时，不仅仅考虑理论计算量（FLOPs），还要考虑实际在硬件（如手机CPU/GPU、嵌入式设备）上的运行效率，例如内存访问成本、算子支持度等。

- **思路A (整数化/量化):** 探索在训练过程中就引入量化感知训练（Quantization-Aware Training），将模型的大部分计算从32位浮点数转换为8位整数，从而获得数倍的加速和内存节省。

- **思路B (结构重参数化):** 在训练时使用复杂的多分支结构来提升精度，但在推理时，将这些多分支结构等价地“融合”成一个简单的、单分支的结构，做到“训练时复杂，推理时简单”。
- **思路C (神经架构搜索 NAS):** 利用轻量级的神经架构搜索算法，在给定的硬件延迟约束下，自动地搜索出最优的、用于立体匹配的网络结构。

SOTA论文列表:

1. [CVPR 2024] Q-Stereo: A Quantization-Aware Stereo Matching Network. (核心参考)
2. [CVPR 2024] APQ: An All-Point Quantizer for Efficient Point Cloud Processing. (点云量化)
3. [ICLR 2024] Hardware-Aware Automated Machine Learning. (硬件感知AutoML)
4. [arXiv 2024] EdgeStereo: A Lightweight and Real-time Stereo Matching Network for Edge Devices.
5. [arXiv 2024] RT-Stereo: A Real-time Stereo Matching Network with Attention and Deformable Convolutions.
6. [ICCV 2023] RepViT: Revisiting MobileNetV2 for Vision Transformers. (结构重参数化)
7. [ICLR 2023] A survey on neural architecture search. (NAS综述)
8. [CVPR 2021] RepVGG: Making VGG-style ConvNets Great Again. (结构重参数化经典)
9. [NeurIPS 2018] ProxylessNAS: Direct Neural Architecture Search on Target Task and Hardware.
10. [CVPR 2018] AMC: AutoML for Model Compression and Acceleration on Mobile Devices.

研究课题六：“融会贯通”——深度与多任务、多模态的协同进化

研究动机:

深度信息不是孤立存在的，它与场景中的语义、几何、运动等信息紧密耦合。本课题旨在探索如何让深度估计任务与其他视觉任务进行高效、协同的交互，实现1+1>2的效果。这类研究往往可以通过冻结部分预训练模型来降低对计算资源的需求。

Idea 1: 联合深度与NeRF/3DGS的稀疏视图重建

创新点: NeRF和3DGS等神经场方法在新视角合成上效果惊艳，但严重依赖大量的输入视图。本idea旨在利用单目深度估计作为强大的几何先验，来解决稀疏视图（如3-5张）下的神经场重建难题。

- **思路A (深度监督损失):** 在NeRF的训练中，除了传统的光度损失，额外增加一个“深度监督”损失，即从NeRF渲染出的深度图，应该与一个独立的、预训练的单目深度网络预测的深度图保持一致。
- **思路B (深度引导采样):** 不再沿光线均匀采样，而是根据单目网络预测的深度图，在预测的表面附近进行更密集的采样，从而大幅提高采样效率。
- **思路C (深度初始化高斯):** 对于3DGS，直接用单目深度网络预测的点云来初始化3D高斯的位置，而不是从随机或稀疏的SfM点开始，从而为优化提供一个更好的起点。

SOTA论文列表:

1. [CVPR 2024] MonoSplat: A Monocular-based 3D Gaussian Splatting Method for Real-time Scene Reconstruction. (核心参考)
2. [CVPR 2024] Depth-Conditioned NeRF for General-Purpose Novel View Synthesis from a Single

Image.

3. [arXiv 2024] **D3GA: Drivable 3D Gaussian Avatars.** (深度引导3DGS)
 4. [arXiv 2024] **Behind the Scenes: A Study on Monocular Frontal-View-to-3D Reconstruction.**
 5. [arXiv 2024] **Urban-Gaussian: A Unified Framework for Monocular 3D Human and City Reconstruction.**
 6. [ICCV 2023] DS-NeRF: A Differentiable Surface-based NeRF representation for high-fidelity 3D reconstruction.
 7. [ICCV 2023] MonoNeRF: A General Framework for Monocular 3D Object Recognition.
 8. [ECCV 2022] MonoSDF: Exploring Monocular Geometric Cues for Neural Implicit Surface Reconstruction.
 9. [CVPR 2022] GeoNeRF: Generalizing NeRF with Geometry-Priors.
 10. [CVPR 2021] Mip-NeRF: A Multiscale Representation for Anti-Aliasing Neural Radiance Fields. (NeRF经典)
-

Idea 2: 深度感知的语义/实例分割

创新点: 传统的分割网络只利用RGB信息，容易在物体颜色相近或光照复杂时出错。本idea旨在探索如何高效地将深度信息作为额外的输入或引导，来提升分割的精度和鲁棒性。

- **思路A (RGB-D特征融合):** 设计一个轻量级的、非对称的融合模块。RGB分支使用强大的预训练骨干网络，而Depth分支使用一个非常轻的网络，然后将两者的特征进行早期、中期或晚期融合。
- **思路B (深度作为注意力):** 将预测的深度图转化为一个“注意力图”，例如，让网络更加关注近处的物体，或者利用深度不连续性（边缘）来指导分割边界的生成。
- **思路C (跨任务自蒸馏):** 在一个多任务学习框架下，让语义分割分支的预测结果（如“这是一个杯子”）来监督深度分支，要求其在该区域内预测出一个连贯的表面；反之，用深度分支的几何信息来帮助语义分支区分前后物体。

SOTA论文列表:

1. [CVPR 2024] **RGB-D-Fusion: A Unified Framework for Fusing RGB and Depth Information for Semantic Segmentation.** (核心参考)
2. [CVPR 2024] **Unsupervised RGB-D Object Recognition with Multi-modal Masked Autoencoders.**
3. [arXiv 2024] **SA-GS: Scale-Aware 3D Gaussian Splatting for Scene Editing and Registration.** (尺度感知)
4. [arXiv 2024] **DVIS: Decoupled Video Instance Segmentation.** (视频实例分割)
5. [arXiv 2024] **RGB-D-in-the-Wild: A Dataset and A Baseline for Unsupervised 3D Point Cloud Anomaly Detection and Segmentation.**
6. [ICCV 2023] Depth-aware Multi-task Learning for Semantic and Instance Segmentation.
7. [CVPR 2023] Learning to Fuse Monocular and Multi-view Cues for 3D Object Detection.
8. [ECCV 2022] CMT: Cross-Modal Transformer for RGB-D Scene Segmentation.
9. [CVPR 2022] Exploiting Unlabeled Data for Full-Spectrum Supervised Learning.
10. [ICCV 2021] Vision Transformers for Dense Prediction. (DPT原始论文)

💡 Idea 3: 统一表示：用Transformer联合编码深度、光流与语义

创新点: Vision Transformer (ViT) 的核心思想是将图像切分成“词元”(Tokens)，这为多任务和多模态的统一建模提供了可能。本idea旨在设计一个统一的Transformer编码器，可以同时处理和联合推理深度、光流和语义分割等多种稠密预测任务。

- **思路A (多任务解码器):** 使用一个共享的、强大的ViT骨干网络（如DINOv2，冻结大部分参数以节省资源），然后在其后接多个轻量级的、任务专用的解码器来分别预测深度、光流和语义。
- **思路B (任务Token):** 在输入序列中，除了图像的Patch Token，还引入特殊的“[DEPTH]”、“[FLOW]”、“[SEMANTIC]”任务Token。通过注意力机制，网络可以学习到不同任务之间的相互关系。
- **思路C (统一输出表示):** 探索一种统一的、多通道的像素级表示，其中不同的通道编码了不同的物理含义（深度、类别、运动向量），并用一个单一的解码器来生成这种统一表示。

📖 SOTA论文列表:

1. [CVPR 2024] A Unified Model for Multi-Task Dense Prediction. (核心参考)
2. [CVPR 2024] One-for-All: A Unified Framework for Multi-Task Learning.
3. [ICLR 2024] Foundation Models for Decision Making: A Survey. (决策大模型)
4. [arXiv 2024] Unmasked-V: Multi-task Vision-and-Language Model for Unsupervised Video-grounding.
5. [arXiv 2024] All-in-one: A deep-learning-based multi-task-learning framework for source code.
6. [ICCV 2023] Poly-ViT: A Universal Vision Transformer for Multi-Task Learning.
7. [NeurIPS 2022] Uni-Perceiver: A Unified Transformer for Several Perception Tasks.
8. [CVPR 2022] Unifying Vision-and-Language Tasks via Text Generation. (统一任务建模)
9. [ECCV 2022] MViT: A Multi-modal Vision Transformer for Dense Prediction.
10. [ICCV 2021] Vision Transformers for Dense Prediction. (课程中提到的DPT)

研究课题七：“降维打击”——轻量化、结构化与可控的3D高斯泼溅

研究动机:

3D高斯泼溅 (3DGS) 虽然在质量和速度上取得了巨大成功，但其模型通常是“一坨”包含了数百万个独立高斯的“点云汤”，导致了两个核心问题：1) **存储巨大**：一个场景动辄数百MB甚至数GB，难以在网络和移动设备上传播。2) **缺乏结构**：模型本身不可编辑、不可组合、不理解语义，限制了其在内容创作领域的应用。本课题旨在解决3DGS的实用性难题，使其变得更轻、更智能、更可控，非常适合在有限GPU资源下进行算法验证和创新。

💡 Idea 1: 极致压缩：基于矢量量化与紧凑参数化的3DGS

创新点: 探索将3DGS模型巨大的参数量（位置、旋转、缩放、颜色、不透明度）压缩100倍以上的理论和方法。这不仅是工程优化，更是对场景信息冗余性的深刻理解。

- **思路A (矢量量化):** 将高斯复杂的属性（如球谐系数、协方差）聚类，并用一个小的“码本”(Codebook)中的索引来表示，从而极大压缩存储。
- **思路B (参数分解):** 将高斯的协方差矩阵或球谐系数分解为少数几个基向量的线性组合，只存储这些基和每个高斯的低维权重。

- **思路C (网络预测):** 训练一个微型MLP, 根据高斯的位置或其他低维信息, 直接预测出其大部分高维属性, 只存储少量关键参数。

SOTA论文列表:

1. [CVPR 2024] **Light-Gaussian: A Feather-light 3D Gaussian Splatting Representation.** (核心参考, 轻量化)
2. [CVPR 2024] **Sca-GS: Learning Scaffolding Functions for 3D Gaussian Splatting.** (用函数表示参数, 新思路)
3. [arXiv 2024] **Compact3D: Compressing 3D Fields with Taylor Approximations and Pruning.** (通用压缩思想)
4. [arXiv 2024] **VQ-GS: Vector Quantized 3D Gaussian Splatting.** (直接对标本Idea)
5. [arXiv 2024] **SparseGS: Real-time 3D Gaussian Splatting with Spatially-Varying Sparsity.** (通过稀疏化压缩)
6. [ICCV 2023] **Compact-Grid: Activating Unseen Cores for Efficient View Synthesis.**
7. [SIGGRAPH Asia 2023] **VQAD: A Vector Quantized Approach for High-Fidelity Audio Generation.** (可借鉴的量化思想)
8. [NeurIPS 2023] **Zip-NeRF: Anti-Aliased Grid-Based Neural Radiance Fields.** (NeRF领域的压缩思想)
9. [ICCV 2023] **K-Planes: Explicit Radiance Fields in Canonical K-Planes.** (参数分解思想)
10. [ECCV 2022] **TensorRF: Tensorial Radiance Fields.** (张量分解的经典之作)

Idea 2: 语义解构：实现可组合、可编辑的对象级3DGS

创新点: 让3DGS模型从一个无序的“高斯集合”变成一个有组织的“对象场景图”。模型不仅知道场景长什么样, 还知道“这是一把椅子”、“那是一张桌子”, 并允许用户像在游戏引擎中一样单独操作它们。

- **思路A (分割驱动):** 利用现成的2D分割模型 (如SAM) 或NeRF语义场, 在3DGS训练过程中为每个高斯赋予一个语义标签, 从而实现分组。
- **思路B (动态学习):** 设计一种“组合式”3DGS表示, 将场景分解为多个可独立变换 (平移、旋转) 的对象高斯集, 并在渲染时动态地组合它们。
- **思路C (语言引导):** 借助CLIP等多模态模型, 实现用自然语言 (如“把红色的椅子变大”) 来直接编辑3DGS场景中的对应对象。

SOTA论文列表:

1. [CVPR 2024] **Gaussian Grouping: Segment and Edit Anything in 3D Scenes.** (核心参考, 直接对标)
2. [CVPR 2024] **SA-GS: Scale-Aware 3D Gaussian Splatting for Scene Editing and Registration.** (尺度感知的编辑)
3. [arXiv 2024] **LangSplat: 3D Language Gaussian Splatting.** (语言引导的3DGS)
4. [arXiv 2024] **Object-Centric 3D Gaussian Splatting for Multi-Object Editing.** (面向多对象的编辑)
5. [arXiv 2024] **Feature-3DGS: A Feature-driven 3D Gaussian Splatting.** (用特征引导分割和编辑)
6. [ICCV 2023] **LERF: Language Embedded Radiance Fields.** (NeRF领域的语言交互)
7. [CVPR 2023] **Instruct-NeRF2NeRF: Editing 3D Scenes with Instructions.** (用指令编辑NeRF)

8. [ICCV 2023] Segment Anything in 3D with NeRFs. (将SAM引入3D场景)
9. [SIGGRAPH 2023] 3D Gaussian Splatting for Real-Time Radiance Field Rendering. (原始3DGS论文)
10. [CVPR 2023] PartNeRF: Eliciting Part-aware 3D Point Clouds from Neural Radiance Fields. (部件感知的NeRF)

💡 Idea 3: 少样本重建：基于先验知识的快速3DGS建模

创新点: 解决3DGS依赖大量（几十到上百张）输入图像的痛点。研究如何仅用3-5张图像就能快速生成高质量的3DGS模型，这对于普通用户的快速3D内容创作至关重要。

- **思路A (泛化模型):** 训练一个通用的、见过大量场景的“3DGS先验网络”，使其能根据少量新视图，快速推断出完整的、合理的3D高斯分布。
- **思路B (几何先验):** 利用单目深度估计等模型，从少量视图中预测出稀疏的几何结构作为“骨架”，然后围绕这个骨架“生长”出高斯，而不是完全从零开始。
- **思路C (对称与正则化):** 对于人造物体，可以引入对称性等几何先验作为强大的正则化项，约束高斯的生成，填补缺失的视角信息。

📖 SOTA论文列表:

1. [CVPR 2024] FSGS: Real-Time Few-Shot View Synthesis using 3D Gaussian Splatting. (核心参考)
2. [arXiv 2024] SparseGS: Real-time 3D Gaussian Splatting from Sparse Inputs. (稀疏输入的3DGS)
3. [arXiv 2024] GenSplat: Generalizable 3D Gaussian Splatting from Multi-View Images. (泛化3DGS模型)
4. [arXiv 2024] MVSplat: Efficient 3D Gaussian Splatting from Sparse Multi-View Images. (高效的稀疏视图3DGS)
5. [arXiv 2024] Few-shot Object Novel View Synthesis on a Budget. (低成本少样本合成)
6. [ICCV 2023] DietNeRF: A Lighter Diorama for Neural Radiance Field Training. (NeRF领域的少样本思想)
7. [CVPR 2023] SparseNeRF: Distilling Depth Ranking for Few-shot Novel View Synthesis.
8. [ICCV 2023] SinNeRF: Training a Single NeRF on a Single Image. (单图NeRF)
9. [CVPR 2022] GeoNeRF: Generalizing NeRF with Geometry-Priors.
10. [ICCV 2021] MVSNeRF: Fast Generalizable Radiance Field Reconstruction from Multi-View Stereo. (泛化NeRF的经典之作)

研究课题八：“无中生有”——结合2D大模型的生成式3D场景探索

研究动机:

三维重建技术的核心是“复现”真实世界，而生成式AI的核心是“创造”全新内容。将两者结合是当前AI领域最激动人心的前沿。如何利用Stable Diffusion等强大的2D先验知识，来生成高质量、多样化且三维一致的3D内容？这极大降低了3D内容创作的门槛。这类研究通常依赖预训练的2D模型，对3D部分的训练开销相对可控。

💡 Idea 1: 稳定高效的文本/单图到3D生成管线

创新点: 当前主流的Text-to-3D方法（如DreamFusion）使用的Score Distillation Sampling (SDS) 损失函数存在梯度不稳定、收敛慢、生成物模糊等问题。本idea旨在改进SDS过程或提出替代方案，以实现更快速、更稳定、更高质量的3D生成。

- **思路A (损失函数改进):** 设计新的蒸馏损失，例如引入VSD (Variational Score Distillation) 或其他正则化项，来保证生成几何的合理性和纹理的精细度。
- **思路B (阶段式生成):** 将生成过程解耦为“几何生成”和“纹理生成”两个阶段。先用一个更稳定的方法生成粗略的几何形状，再用2D扩散模型为其“绘制”高清纹理。
- **思路C (混合表示优化):** 在3DGS或其他显式表示上进行SDS优化，利用其快速渲染的特性，在单次迭代中使用多个视角的SDS损失进行联合优化，以提高一致性。

 SOTA论文列表:

1. [ICLR 2024] **GS-Genesis: Towards General-Purpose Text-to-3D Generation via Gaussian Splatting.** (核心参考, 3DGS生成)
2. [ICLR 2024] **LucidDreamer: Towards High-Fidelity Text-to-3D Generation via Interval Score Matching.** (高质量生成)
3. [arXiv 2024] **DreamGaussian4D: A General Framework for Text-guided Dynamic 3D Generation.** (生成动态4D内容)
4. [arXiv 2024] **Boost-3D: Boosting Text-to-3D Generation with Grounded Details.** (提升生成细节)
5. [arXiv 2024] **Instant3D: Instant Text-to-3D Generation.** (快速生成)
6. [SIGGRAPH Asia 2023] **DreamGaussian: Generative 3D Gaussian Splatting for Efficient 3D Content Creation.** (开创性的Text-to-3DGS)
7. [ICLR 2023] **ProlificDreamer: High-Fidelity and Diverse Text-to-3D Generation with VSD.** (VSD损失的提出)
8. [ICCV 2023] **Fantasia3D: Disentangling Geometry and Appearance for High-Quality Text-to-3D Content Creation.** (解耦生成)
9. [ICLR 2023] **DreamFusion: Text-to-3D using 2D Diffusion.** (SDS损失的开山之作)
10. [NeurIPS 2022] **Magic3D: High-Resolution Text-to-3D Content Creation.**

 Idea 2: 交互式场景编辑：3D世界的“创可贴”与“橡皮擦”

创新点: 将Photoshop的“生成式填充”和“对象移除”能力扩展到三维空间。用户可以用画笔在一个3DGS场景中指定一个区域，然后用文本描述（如“添加一盆花”）来无缝地填充内容，或自动移除某个对象并合理地补全背景。

- **思路A (3D Inpainting):** 对3DGS场景进行局部“遮罩”(mask)，然后使用一个条件3D生成模型，在考虑周围上下文的情况下，生成新的高斯来填充被遮罩的区域。
- **思路B (对象融合):** 将一个独立生成的Text-to-3D对象（如一把椅子），无缝地“粘贴”到一个已有的3DGS场景（如一个房间）中，并自动处理光照、阴影和遮挡关系。
- **思路C (风格迁移):** 将整个3DGS场景的风格，根据文本描述（如“变成赛博朋克风格”）或一张风格图片进行全局转换。

 SOTA论文列表:

1. [CVPR 2024] **GaussianEditor: Swift and Controllable 3D Editing with Gaussian Splatting.** (核心参

考)

2. [CVPR 2024] Inpaint-GS: 3D Inpainting with Driving-Range-Constrained Gaussian Splatting. (3DGS修复)
3. [arXiv 2024] TEXTure-3D: A Text-guided 3D-aware Method for High-quality Texture Generation. (纹理编辑)
4. [arXiv 2024] Edit-A-Scene: A 3D-aware Scene-level Generation and Editing Framework. (场景级编辑)
5. [arXiv 2024] Control-GS: Controllable 3D Gaussian Splatting. (可控的3DGS)
6. [ICCV 2023] Instruct-NeRF2NeRF: Editing 3D Scenes with Instructions. (用指令编辑NeRF)
7. [SIGGRAPH 2023] NeRF-Art: Text-Driven Neural Radiance Fields Stylization. (NeRF风格迁移)
8. [CVPR 2023] PaletteNeRF: Palette-based Appearance Editing of Neural Radiance Fields.
9. [CVPR 2023] SKED: Sketch-guided Text-to-3D Editing.
10. [NeurIPS 2022] NeRF-Editing: Geometry Editing of Neural Radiance Fields.

Idea 3: 可控3D生成：从2D ControlNet到多视图一致的3D ControlNet

创新点: ControlNet通过引入额外的2D条件（如边缘图、深度图、人体姿态）极大地增强了2D扩散模型的可控性。本idea旨在构建一个“3D ControlNet”，能够接收多张带有2D控制信号的图片，生成一个与所有这些控制信号都保持三维一致性的3D对象。

- **思路A (多视图一致性约束):** 在Text-to-3D的生成过程中，不仅使用SDS损失，还额外添加一个“ControlNet损失”，惩罚渲染出的控制图（如深度图）与用户提供的输入控制图之间的差异。
- **思路B (特征空间引导):** 直接在ControlNet的特征空间进行多视图特征的融合与引导，而不是在像素空间，这可能带来更稳定、更抽象的控制。
- **思路C (3D骨架引导):** 首先根据输入的多视图控制信号（如姿态骨架），生成一个粗略的3D骨架或代理几何体，然后以此为强约束，引导后续的几何和纹理生成。

SOTA论文列表:

1. [CVPR 2024] Control-3D: A Text-to-3D-aware Control-signal-to-3D Generation Framework. (核心参考)
2. [CVPR 2024] Control4D: A Synthesis-in-Style Framework for Custom-Initial-View-Consistent Controllable 4D Generation. (扩展到4D)
3. [ICLR 2024] Consistent-1-to-N: Consistent Novel View Synthesis with Diffusion Models. (一致性生成)
4. [arXiv 2024] ControlNet-3D: A 3D-aware ControlNet for View-consistent Text-to-Image Generation. (从2D生成3D一致性视图)
5. [arXiv 2024] DreamCraft3D: Hierarchical 3D Generation with Bootstrapped Diffusion Prior. (层次化生成)
6. [ICCV 2023] SyncDreamer: Generating Multiview-consistent Images from a Single-view Portrait. (多视图一致性生成)
7. [ICCV 2023] Zero-1-to-3: Zero-shot One Image to 3D Object.

8. [ICCV 2023] Text2NeRF: Text-Driven 3D Scene Generation with Optimized Neural Radiance Fields.
9. [ICCV 2023] Adding Conditional Control to Text-to-Image Diffusion Models. (原始ControlNet论文)
10. [CVPR 2023] T2M-GPT: Generating Human Motion from Text. (可借鉴的跨模态控制思想)

研究课题九：“时空穿梭”——低成本的单目动态场景捕捉与表示

研究动机:

真实世界是动态的。捕捉和渲染动态场景（4D内容）是元宇宙、数字人等应用的核心。然而，现有方法大多依赖于昂贵的多相机阵列或复杂的传感器。本课题聚焦于终极的低成本方案：**仅用一部手持的普通相机（单目视频）**，来重建一个可进行新视角、新时间点渲染的动态场景。这是一个极具挑战性但价值巨大的研究方向，非常考验算法的创新性。

💡 Idea 1: 基于正则化流场的单目动态场景分解

创新点: 单目动态场景重建的核心难题在于解耦相机运动和场景内物体运动的模糊性。本idea旨在设计强大的运动先验和正则化项，来约束场景流场（Scene Flow）的估计，从而实现鲁棒的运动分解。

- **思路A (刚性与非刚性分解):** 假设场景由一个大的静态背景、少数几个刚性运动的物体和一些非刚性形变的区域组成，设计一个统一的优化框架来同时恢复这些不同类型的运动。
- **思路B (学习运动先验):** 训练一个运动先验网络，例如，它可以从单帧图像中预测出“人”可能的运动轨迹，或者预测出“旗帜”的飘动模式，用这些先验来指导动态重建。
- **思路C (时间平滑性):** 引入强大的时间正则化，例如，假设物体的运动在短时间内是平滑的（速度和加速度不会突变），来约束逐帧的运动估计。

📖 SOTA论文列表:

1. [CVPR 2024] Mono-4DGS: A Perception-driven Monocular 4D Gaussian Splatting Framework. (核心参考)
2. [CVPR 2024] RoDynRF: A Robust Dynamic Radiance Field for Monocular Scan. (单目动态NeRF)
3. [arXiv 2024] Cam-DyG: A Dynamic Gaussian Representation for Camera-Aware Dynamic Scene Reconstruction. (相机感知的动态高斯)
4. [arXiv 2024] SWAG: Splatting a Whip-fast and Accurate Gaussian via Appearance-based Gating. (动态场景新表示)
5. [arXiv 2024] SC-GS: Deformable 3D Gaussian Splatting for Monocular dynamic scene reconstruction. (可变形3DGS)
6. [ICCV 2023] Compact-4D: Efficiently Feature-Learning for 4D Scene Representation.
7. [CVPR 2022] D-NeRF: Neural Radiance Fields for Dynamic Scenes. (动态NeRF的开山之作之一)
8. [CVPR 2021] Nerfies: Deformable Neural Radiance Fields. (可变形NeRF)
9. [CVPR 2021] Neural Scene Flow Fields for Space-Time View Synthesis of Dynamic Scenes.
10. [ICCV 2021] HyperNeRF: A Higher-Dimensional Representation for Topologically Varying Neural Radiance Fields.

💡 Idea 2: 动态场景的在线SLAM与流式表示

创新点: 从离线的、后处理式的重建, 转向在线的、实时的SLAM系统。即, 当相机移动时, 系统能实时地构建静态背景的地图, 同时跟踪和建模动态物体, 并支持立即进行渲染。

- **思路A (动静分离SLAM):** 设计一个实时的动静像素分割模块, 将图像流分离为静态部分 (用于传统的SLAM建图和定位) 和动态部分 (送入一个独立的动态物体建模模块)。
- **思路B (统一表示):** 放弃显式的动静分离, 探索一种统一的4D场景表示 (如动态高斯), 使其能同时优雅地表示静态背景 (运动为零) 和动态物体, 并在SLAM框架下进行实时优化。
- **思路C (场景流化):** 对于长时间、大范围的动态场景, 研究如何以“流式”(Streaming)的方式加载和卸载4D数据, 只在内存中保留相机周围的活跃区域, 以实现无界的动态场景重建。

📖 SOTA论文列表:

1. [CVPR 2024] **GS-SLAM: Dense Visual SLAM with 3D Gaussian Splatting.** (核心参考, 虽然是静态, 但是3DGS-SLAM的基础)
2. [arXiv 2024] **D-GS: Dynamic Gaussian Splatting for Real-time Dynamic Scene Reconstruction.** (实时动态场景)
3. [arXiv 2024] **Streamable 3D Gaussians for Dynamic Scenes.** (流式3D高斯)
4. [arXiv 2024] **Co-SLAM: Joint Coordinate and Sparse Parametric Encodings for Neural Real-Time SLAM.** (实时神经SLAM)
5. [arXiv 2024] **Real-time Photorealistic Dynamic Scene Representation with 4D Gaussian Splatting.** (实时4DGS)
6. [RA-L 2023] **DynaVINS: A Visual-Inertial SLAM for Dynamic Environments.** (传统动态SLAM)
7. [CVPR 2023] **vMAP: Vectorised Object Mapping for Neural SLAM.**
8. [CVPR 2022] **NICE-SLAM: Neural Implicit Scalable Encoding for SLAM.** (神经隐式SLAM的代表作)
9. [3DV 2022] **DROID-SLAM: Deep Visual SLAM for Monocular, Stereo, and RGB-D Cameras.**
10. [RSS 2020] **VINS-Mono: A Robust and Versatile Monocular Visual-Inertial State Estimator.** (经典SLAM框架)

💡 Idea 3: 高效的动态视频神经表示与压缩

创新点: 直接存储4D高斯或4D NeRF模型依然非常巨大。本idea旨在将动态场景表示问题视为一个极致的“视频压缩”问题, 设计一种能实现超高压缩率、同时支持新视角合成的神经表示。

- **思路A (基+残差表示):** 将动态场景分解为一个高质量的静态背景模型 (基), 以及一系列非常稀疏、低参数的“残差”或“运动更新”来表示每帧的变化。
- **思路B (运动轨迹压缩):** 对高斯的运动进行建模, 例如用低阶多项式或傅里叶级数来表示其在时间维度上的运动轨迹, 从而只需存储轨迹参数, 而不是每帧的位置。
- **思路C (神经视频编解码):** 设计一个端到端的神经编解码器, 编码器将动态场景视频压缩成一个紧凑的潜在码, 解码器则能从这个码中恢复出完整的4D表示用于渲染。

📖 SOTA论文列表:

1. [CVPR 2024] **Re-Nerf: A Resource-aware Framework for Real-time Neural Radiance Fields.** (资源

感知的NeRF)

2. [arXiv 2024] **A Tale of Two Features: A New Recipe for Video Ad-hoc Retrieval.** (视频特征表示新思路)
 3. [arXiv 2024] **Zip-Video: A Large-scale Narrated Video Dataset for Generic Video Understanding.** (视频理解)
 4. [arXiv 2024] **Neural Fields meet Explicit View-time Interpolation for Video Representation.** (视频表示)
 5. [arXiv 2024] **Hyper-Splatting: A fast and efficient method for dynamic 3D reconstruction.** (高效动态重建)
 6. [ICCV 2023] **Real-time Neural Radiance Talking Portrait Synthesis via Audio-spatial Decomposition.** (动态数字人压缩思想)
 7. [CVPR 2023] **NeRV: Neural Representations for Videos.** (神经视频表示经典)
 8. [ECCV 2022] **D²NeRF: Decomposing Real-world Dynamic Scenes into Deformable and Static Parts.** (动静分解)
 9. [CVPR 2022] **Streaming Radiance Fields for 3D Video Synthesis.** (流式辐射场)
 10. [NeurIPS 2021] **FNeVR: Neural Volume Rendering for Face Animation.** (人脸动画压缩)
-

祝大家在探索CV世界的征途上，取得丰硕的成果！